

Jak třídit bankovní transakce pomocí lokálního LLM

XLLMA: od přípravy dat ke třem experimentům s českými transakcemi.

Dokáže jazykový model rozpoznat účel platby a navrhnout užitečné kategorie?

Testujeme Qwen na smyšlených bankovních výpisech. Sledujeme kvalitu zařazení, rychlost i srozumitelnost navržených kategorií.

CO ČTENÁŘ ZJISTÍ

Úloha → postup → výsledky

Co model dostal.
Jak jsme měřili výsledek.
Co z něj lze vyvodit.

10 625

syntetických transakcí

3

dokončené experimenty

1 lokální model

Qwen3.5:4b

Podklad: DOKUMENTACE_PROJEKTU.md a uložené výsledky experimentů.

Co má model rozhodnout u jedné platby?

Každé transakci přiřazuje dvě úrovně: konkrétní účel a širší oblast výdajů.

VSTUP Z VÝPISU

Lidl • –450 Kč

Typ: platba kartou

Poznámka: prázdná

Model vidí obchodníka a částku, nikoli obsah nákupního košíku.



PODROBNÁ KATEGORIE

Potraviny

Odpovídá na otázku:
„Jaký je účel této platby?“

Další příklady: nájem, léky,
telefon a internet.



HLAVNÍ KATEGORIE

**Potraviny a
stravování**

Sdružuje více účelů.

Do stejné širší oblasti patří
například potraviny,
restaurace a kavárny.

Tato vazba tvoří hierarchii kategorií: podrobná kategorie musí patřit do zvolené hlavní skupiny.

Qwen rozhoduje; Ollama ho spouští na počítači

LLM znamená velký jazykový model: pracuje s textem a odpovídá podle zadaných instrukcí.

MODEL

Qwen3.5:4b

Model interpretující český bankovní text.

V projektu používáme stejnou uloženou verzi modelu pro všechny tři experimenty.

PROGRAM PRO SPUŠTĚNÍ

Ollama

Zpřístupňuje model místně na počítači.

Náš program jí posílá transakce a přijímá odpovědi. Zpracování v těchto bžích probíhá bez cloudové služby.

ZADÁNÍ ÚLOHY

Instrukce v požadavku

Před každou odpovědí model dostane pravidla a seznam kategorií.

Na těchto datech model nepřeučujeme. Změna instrukcí není jeho trénink.

Model kategoriím rozumí z aktuálního zadání. Není nutné mu je předem natrénovat.

Od soukromého výpisu k bezpečné testovací sadě

Příprava dat se měnila podle kontroly kvality a požadavku na ochranu soukromí.

1

Sjednocení výpisů

Sloučení tabulkových výpisů (CSV). Jména osob byla konzistentně nahrazena smyšlenými.

2

Rozšíření o smyšlené transakce

Přidali jsme různé životní situace, služby a dovolené. Názvy firem a četnost poznámek prošly revizí.

3

Úplná náhrada soukromých plateb

Samotná změna jmen by zachovala osobní návyky. Proto jsme 9. 10. 2026 nahradili i původní transakce.

Všechny výsledky v této prezentaci pocházejí ze současných, plně syntetických dat.

Dvě smyšlené sady, celkem 10 625 transakcí

Označení „referenční“ je název menší sady; dnes také obsahuje pouze smyšlené platby.

1 625

menší referenční sada

9 000

hlavní syntetická sada

12

smyšlených profilů v hlavní sadě

ROZMANITOST

Různé životní situace

Například student, rodina s dětmi, senior, podnikatel, cestovatel nebo člověk s domácím zvířetem.

ČAS A MĚNA

Leden 2022 - říjen 2026

Zaúčtované částky jsou v Kč. Část plateb uchovává i původní cizí měnu. Rok 2026 je neúplný.

Podoba výpisu je realistická, chování je vymyšlené

Generátor skládá platby z předem popsanych situací, nikoli ze zachovaných osobních návyků.

OBCHODNÍCI A SLUŽBY

Veřejné názvy firem

Firmy a poskytovatelé vycházejí z ověřovaného katalogu. Smyšlená jsou jména osob.

Koš zahrnuje bydlení, dopravu, péči, digitální služby i cestování.

ČÁSTKY A OPAKOVÁNÍ

Modelové předpoklady

Profily určují četnost a rozsah výdajů. Generátor vytváří opakované platby i jednorázové nákupy.

Ceny, kurzy a vývoj v čase jsou zvolené předpoklady.

Vyplněné textové pole	Počet transakcí	Podíl
Popis pro mě	426	4,01 %
Zpráva pro příjemce	5 315	50,02 %

Podklad: generate_synthetic.py; merchant_catalog.json; skutečné četnosti ve společném CSV.

EDA: nejprve zjišťujeme, co data obsahují

EDA je průzkumná analýza dat: kontrola kvality a popis rozložení před modelováním.

Kontrola společného výpisu	Výsledek
Jedinečné identifikátory transakcí	10 625
Neplatná data nebo částky	0
Úplně duplicitní řádky	0
Řádky se znakem poškozeného textu	0

CO JE TŘEBA ZOHLEDNIT

Prázdná poznámka je běžná

Osobní popis chybí u přibližně 96 % plateb. Model často musí vycházet z názvu protistrany a typu operace.

Příjmy a výdaje ani jednotlivé kategorie nejsou zastoupeny stejně.

EDA také sleduje čas, částky a kategorie. Výdaj může být převod či výběr hotovosti; součet pohybů není zůstatek účtu.

Podklad: project/notebooks/EDA.ipynb; kontrola současného data_combined.csv.

Tři různé způsoby, jak vznikne kategorie

Rozlišujeme známý záměr generátoru, odhad pravidel a odhad jazykového modelu.

1 · ZÁMĚR GENERÁTORU

Scénář transakce

Při tvorbě platby se uloží, co měla představovat, například telefon nebo nájem.

S tímto záměrem porovnáváme výsledek modelu.

2 · ODHAD Z PRAVIDEL

Heuristický štítek

Ručně napsaná pravidla využívají typ operace, protistranu a poznámky.

V menší sadě neurčí účel u 786 z 1 625 plateb, tedy 48,37 %.

3 · ODHAD MODELU

Predikce Qwenu

Model čte bankovní údaje a rozhoduje podle instrukcí.

Nedostává záměr generátoru ani dříve přiřazený štítek.

Štítek je název kategorie u řádku. Neurčeno u pravidel není chyba CSV ani naměřená chyba Qwenu.

Co model vidí a jak získáváme jeho odpověď

Pro jednu platbu nebo dávku plateb proběhne stejný postup.

BANKOVNÍ ÚDAJE

Sedm vstupních polí

Datum provedení
Název protiúčtu
Částka a měna
Typ transakce
Popis pro mě
Zpráva pro příjemce



ZADÁNÍ MODELU

Údaje + instrukce

Skript přidá povolené
kategorie a pravidla.

Qwen vrátí podrobnou i
hlavní kategorii pro
každou položku.



ULOŽENÍ A KONTROLA

Dvě rozhodnutí

Skript ověří úplnost a
platné kódy kategorií.

Teprve při hodnocení
spojí odpovědi se
záměrem generátoru.

Skryté před modelem: scénář, profil osoby a jeho kategorie. Model v těchto bžích nehledá obchodníky na internetu.

Tři běhy odpovídají na dvě odlišné otázky

Dávka znamená více transakcí v jednom požadavku; nejde o souběžné spuštění více modelů.

A · PEVNÉ KATEGORIE

16 transakcí najednou

Model vybírá z připraveného seznamu: 89 podrobných kategorií a 15 hlavních skupin.

Základní měření kvality a rychlosti.

B · STEJNÉ KATEGORIE

1 transakce v požadavku

Stejný model, bankovní údaje a instrukce jako v běhu A.

Zjišťujeme, co se změní při odděleném posuzování každé platby.

C · VLASTNÍ KATEGORIE

Nejprve návrh seznamu

Qwen vytvoří kategorie ze vzorku dat. Pak do nich zařadí celý dataset po 16 transakcích.

Zjišťujeme kvalitu samotného návrhu i rozdělení plateb.

Pevný seznam obsahuje i kategorie bez transakcí. Ve scénářích dat je skutečně zastoupeno 68 kategorií a 14 hlavních skupin.

Co zde znamená „přesnost“?

Počítáme podíl plateb, kde model vybral stejnou kategorii jako scénář generátoru.

Shoda = počet shodných kategorií ÷ počet všech hodnocených transakcí

JEDNODUCHÝ PŘÍKLAD

58 shod ze 100 plateb → 58 %

Podrobnou a hlavní kategorii hodnotíme zvlášť. Širší oblast lze trefit i při chybném konkrétním účelu.

HRANICE TOHOTO MĚŘENÍ


Známe záměr tvorby, nikoli nákup

Bankovní text někdy neprozradí původní záměr. Například hotel může znamenat ubytování i jinou službu.

Shoda se smyšlenými scénáři neproказuje stejnou kvalitu na skutečných účtech ani správnost každého věcného úsudku.

Dávka 16 zde vedla k vyšší shodě než jednotlivé platby

Oba běhy označily stejných 10 625 transakcí. Mění se velikost dávky a odpovídající limit odpovědi.



JAK ČÍSLA ČÍST

**Přibližně 58 vs. 45
shod ze 100**

Rozdíl podrobné shody je 13,08 procentního bodu.

Jde o výsledek jednoho modelu, zadání a datasetu, nikoli o obecné pravidlo pro dávkování.

Vyšší shoda hlavní kategorie znamená, že model častěji pozná širší oblast platby než její přesný účel.

Macro-F1 dává prostor i méně častým kategoriím

Celkovou shodu mohou ovládnout časté platby, například pravidelné účty a předplatné.

CO JE F1

Spojuje dva pohledy

Přesnost přiřazení: kolik plateb označených jako „léky“ jsou skutečně scénáře léků?

Záchyt: kolik všech scénářů léků model našel?

F1 kombinuje oba podíly; maximum je 1.

Macro-F1 = průměr F1 kategorií, každá má stejnou váhu.

Úroveň	16 najednou	Po jedné
Podrobná	0,4048	0,3766
Hlavní	0,6894	0,6382

Skóre 0-1; vyšší hodnota je lepší.

U podrobných kategorií je skóre výrazně slabší než prostá shoda. Úspěch je mezi kategoriemi nerovnoměrný.

Podklad: evaluate_llm.py; evaluation.json. Průměr zahrnuje kategorie skutečně zastoupené ve scénářích.

Po jedné platbě byl běh pomalejší a častěji nerozhodl

Neurčeno je platná odpověď modelu, když podle instrukcí nedokáže doložit účel platby.

Metrika pro celý dataset	A: 16 najednou	B: po jedné
Evidovaný čas klasifikace	40,55 min	88,68 min
Platby s neurčeným účelem	324 / 10 625	1 270 / 10 625
Podíl neurčeného účelu	3,05 %	11,95 %
Kategorie nepatří do vybrané hlavní skupiny	33 plateb	43 plateb

Po jedné trvala klasifikace přibližně 2,19× déle. Oba běhy vrátily úplné odpovědi pro všechny transakce.

Podklad: run.json a evaluation.json; stejné prostředí, jeden souběžný požadavek.

Výrazný propad souvisí s telefonem a internetem

Podíváme se na konkrétní scénářové kategorie, nejen na celkové průměry.

694 / 800

telefonních scénářů zachyceno v dávce 16

0 / 800

telefonních scénářů zachyceno po jedné

694

plateb zhoršených právě v této kategorii

POZOROVANÝ VÝSLEDEK

O2 → jiný účel než telefon

Běh po jedné například řadil O2 do bankovních poplatků. Výstupy byly úplné a nenarazily na limit délky.

MOŽNÉ VYSVĚTLENÍ

Dávka mění kontext rozhodování

Další položky či již vytvořené odpovědi mohou pomoci s výběrem kódů. Jde o hypotézu; přesná příčina nebyla prokázána.

Model nejprve navrhl seznam a potom označil data

Taxonomie je seznam kategorií, jejich popisů a vazeb na hlavní skupiny.

1 • KROK

512 plateb

Náhodný vzorek bez scénářových štítků.



2 • KROK

8 návrhů

Každý návrh vznikl z 64 plateb.



3 • KROK

29 + 14

Model sloučil návrhy do 29 kategorií a 14 skupin.



4 • KROK

10 625 štítků

Celý výpis označil s tímto pevným návrhem.

Hlavní hodnocení používá 10 113 zbývajících plateb, které model při návrhu kategorií neviděl.

Návrh trval evidovaných 3,29 minuty; následná klasifikace 39,99 minuty. Během klasifikace už model kategorie nesměl měnit.

Podklad: discover_categories.py; discovery.json; taxonomy.json; run.json experimentu C.

Vznikl použitelný základ, ale také konkrétní vady

Významové vady jsme ručně neopravovali, aby výsledek zachycoval skutečný návrh modelu.

CHYBA V SEZNAMU

Neurčitý účel pod příjmy

Model přiřadil kategorii „Neurčitý účel“ do skupiny „Příjmy z práce a sociálního zabezpečení“.

Taková vazba nemá smysl pro obecné neznámé platby.

CHYBA PŘI OZNAČOVÁNÍ

164 porušení hierarchie

Například Lékárna ISCARE: „Lékárna a zdravotnictví“ + „Pojistné a služby“.

Podle vlastního seznamu měla být hlavní skupina „Zdravotnictví a péče“.

DALŠÍ ZJIŠTĚNÍ

Nejasné hranice kategorií

Sportovní i cestovní kategorie se významově překrývají.

924 plateb má neurčený účel (8,70 %).

Jedna z 29 kategorií se nepoužila.

Srozumitelný název nestačí: důležité jsou také hranice kategorií a správné vztahy mezi nimi.

Jiný název nemusí znamenat jiné rozdělení plateb

U nově navržených kategorií nelze prostě porovnávat jejich názvy s původním seznamem.

Ilustrační protistrana	Scénářová kategorie	Možný nový název
Lidl	Potraviny	Supermarkety
BILLA	Potraviny	Supermarkety
České dráhy	Veřejná doprava	Doprava vlakem
RegioJet	Veřejná doprava	Doprava vlakem

V této ukázce se názvy liší, ale dvojice podobných plateb zůstávají spolu. Proto hodnotíme i samotné rozdělení do skupin.

Podklad: Ilustrace principu hodnocení; tabulka nepředstavuje měření konkrétních řádků.

Dvě skóre hodnotí rozdělení, nikoli shodu názvů

Obě metriky porovnávají skupiny vytvořené modelem se skupinami podle scénářů generátoru.

ARI • UPRAVENÝ RANDŮV INDEX

Zůstaly podobné platby spolu?

Porovnává dvojice transakcí: shodnou se obě rozdělení, že dvojice patří spolu, nebo naopak zvlášť?

Zohledňuje shodu vzniklou náhodou.

1 = stejné rozdělení; $0 \approx$ náhodná shoda. Skóre může být i záporné.

V-MEASURE

Jsou skupiny čisté a celistvé?

Čistota: nová kategorie nesměšuje různé scénářové účely.

Celistvost: jeden scénářový účel se nerozpadá do více nových kategorií.

Vyvažuje obě vlastnosti. Rozsah je 0–1, maximum 1.

Vyšší skóre znamená větší podobnost rozdělení. ARI 0,66 ani V-measure 0,71 neznamenají „66 %“ či „71 % správných transakcí“.

Vlastní návrh kategorií nemá jednoznačně lepší výsledek

Srovnáváme oba seznamy na stejných 10 113 transakcích mimo vzorek použitý k návrhu.

Úroveň kategorií	Použitý seznam	ARI	V-measure
Podrobná	A: připravený seznam	0,5960	0,7357
Podrobná	C: návrh Qwenu	0,6605	0,7144
Hlavní	A: připravený seznam	0,5707	0,6392
Hlavní	C: návrh Qwenu	0,4295	0,5472

Podrobné kategorie: lepší ARI, ale horší V-measure.

Hlavní skupiny: obě metriky jsou slabší než u pevného seznamu.

Podklad: evaluation.json experimentu C, sekce held_out a baseline. Skóre zaokrouhlena na 4 desetinná místa.

Co projekt ukázal — a kam zatím závěry nesahají

Je to ověřený experiment na syntetických datech, nikoli hotový nástroj pro osobní finance.

OVĚŘENO

Lokální třídění funguje

Qwen zpracoval všechny transakce a vracel strukturované odpovědi.

Dávka 16 dosáhla v našem srovnání vyšší shody a nižšího času než běh po jedné.

OVĚŘENO

Seznam kategorií lze navrhnout

Model vytvořil a použil vlastní kategorie.

Kvalita ale závisí i na definicích a hierarchii. Návrh vyžaduje obsahovou kontrolu před praktickým nasazením.

OMEZENÍ

Reálná přesnost zatím není známá

Data i hodnoticí štitky vytvořil generátor.

Měřili jsme jeden model a jeden dokončený běh každé konfigurace. Výsledek může využívat pravidelnosti generátoru.

Největší otevřená otázka: jak se model zachová na nezávisle označených, dosud neviděných platbách?

Další experimenty mají rozlišit příčiny od náhod

Následující kroky jsou doporučení; nejsou součástí už naměřených výsledků.

Navržený krok	Co tím ověříme
Nezávislé ruční označení transakcí	Shodu s lidským posouzením a nejednoznačné případy.
Noví obchodníci mimo návrhový vzorek	Zda model rozpozná účel mimo známé názvy.
Promíchat pořadí a zkusit více velikostí dávek	Vliv kontextu, pozice transakce a opakovatelnosti.
Porovnat jiné modely a instrukce	Zda propad po jedné souvisí s konkrétním modelem či zadáním.
Revize kategorií a hlavních skupin	Srozumitelnější hranice a méně rozporů v hlavních skupinách.

Pro hlavní výsledek držet stranou vzorek, který se nepoužil k úpravám instrukcí ani kategorií.

Podklad: DOKUMENTACE_PROJEKTU.md, Doporučené další kroky; diagnostika experimentu B.

Společná nastavení klasifikace a uchované záznamy

Token je jednotka textu zpracovávaná modelem; jeho počet není totožný s počtem slov.

Parametr	Hodnota	Co ovlivňuje
Model / spuštění	Qwen3.5:4b / Ollama 0.34.0	Stejná uložená verze ve všech klasifikacích.
Temperature / seed	0 / 42	Omezení náhodnosti / pevné počáteční nastavení.
Kontext	8 192 tokenů	Prostor pro instrukce, data a odpověď.
Limit odpovědi	80 × počet položek	80 tokenů po jedné, 1 280 pro dávku 16.
Souběžnost / režim think	1 požadavek / vypnuto	Žádná paralelizace; rozšířený režim uvažování vypnut.
Návrh kategorií v běhu C	Kontext 16 384 / 32 768	Větší prostor pro dílčí návrhy / jejich sloučení.

run.json uchovává nastavení a kontrolní součty vstupů; průběžný záznam odpovědí umožňuje pokračovat v přerušeném běhu. Úplnost, kódy a vazby se ověřují při vyhodnocení.

Podklad: run.json pro A, B a C; discovery.json; DOKUMENTACE_PROJEKTU.md, Parametry experimentů.

Jak vznikla shoda 62,21 % u vlastních kategorií?

Jde o statistické přiřazení k původním scénářům, nikoli o ručně ověřené překlady kategorií.

PŘÍRAZENÍ NA VZORKU

Nejčastější scénář v nové kategorii

Na 512 návrhových řádcích ke každé nové kategorii přiřadíme nejčastější scénářový účel.

Vazbu použijeme na 10 113 zbývajících řádků. U podrobných štítků zůstane neurčená či neviděná kategorie nepřirazená.

Úroveň	Shoda	Macro-F1
Podrobná	62,21 %	0,2253
Hlavní	63,18 %	0,4081

Více nových kategorií se může přiřadit ke stejnému scénáři. Nízké podrobné Macro-F1 ukazuje nerovnoměrné pokrytí účelů.

62,21 % nelze přímo srovnávat s 58,26 % běhu A: liší se seznam, způsob hodnocení i výběr řádků. Hlavní srovnání proto používá ARI a V-measure na stejných datech.

Podklad: evaluate_discovered.py; evaluation.json, calibration_mapping a held_out.mapped_scores.

Kde najít podrobný postup a výsledky

Následující cesty jsou uvnitř projektu XLLMA. PDF tvoří samostatný přehled; soubory umožní hlubší kontrolu.

Celý proces: **DOKUMENTACE_PROJEKTU.md**

Vývoj dat, ochrana soukromí, opravy, parametry, interpretace a omezení experimentů.

Data a průzkumná analýza

data/README.md

Význam sad a postup spuštění.

data/transactions/ a data/profiles/

Výpisy a hodnoticí scénáře.

project/notebooks/EDA.ipynb

Průzkum kvality a rozložení dat.

Měření jednotlivých experimentů

data/experiments/

- qwen3.5_4b_all_categories/ — A
- qwen3.5_4b_single_t0/ — B
- qwen3.5_4b_discovered/ — C

V každé složce: evaluation_report.md, evaluation.json, run.json a predikce. B navíc porovnání; C návrh kategorií.